

西瓜书复习笔记06

- 间隔与支持向量
 - 什么是SVM：

对于二分类问题，SVM就是在样本数据中计算一个最优超平面，然后把样本数据分割成不同的类别，并且能对新数据进行分类。
 - SVM和LR区别：
 - 相同点：

都是分类算法
都是监督学习
都是判别式模型
都是线性模型
 - 不同点：

损失函数（目标函数）不同（LR：是基于概率理论和极大似然估计；SVM：是基于几何间隔最大化原理）。

线性SVM是距离度量，需要normalization。

SVM自带正则化，LR必须额外添加。

SVM有核函数，LR一般不用核函数
 - 输出标签：

二分类问题，标签是{-1, +1}
 - 划分超平面：

将不同类别的养分分开的超平面。

这个划分超平面受训练集局限性和噪点影响。

这个划分超平面分类的结果是最鲁棒的，对未见样本泛化能力最强。
 - 划分超平面描述（线性方程）：

$$\mathbf{w}^T \mathbf{x} + b = 0$$

其中：

w为法向量，决定了超平面的方向；

b为位移项，决定了超平面与原点的距离。

- 支持向量：

支持平面上把两类划分开的超平面的向量点，即距离超平面最近的几个训练样本点。
- 手推SVM：
 - 间隔：

$$r = \frac{|\mathbf{w}^T \mathbf{x} + b|}{\|\mathbf{w}\|}$$

其中：

$$\begin{aligned} \mathbf{w}^T \mathbf{x}_i + b &\geq +1, & y_i &= +1 \\ \mathbf{w}^T \mathbf{x}_i + b &\leq -1, & y_i &= -1 \end{aligned}$$

$$\|\mathbf{w}\| = \sqrt{w_1^2 + w_2^2 + \dots}$$

则有

$$\gamma = \frac{2}{\|\mathbf{w}\|}$$

■ 最大间隔：

$$\begin{aligned} \max_{\mathbf{w}, b} \quad & \frac{2}{\|\mathbf{w}\|} \\ \text{s.t.} \quad & y_i (\mathbf{w}^T \mathbf{x}_i + b) \geq 1, \quad i = 1, 2, \dots, m \end{aligned}$$

等价于：

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{1}{2} \|\mathbf{w}\|^2 \\ \text{s.t.} \quad & y_i (\mathbf{w}^T \mathbf{x}_i + b) \geq 1, \quad i = 1, 2, \dots, m \end{aligned}$$

这是SVM的基本型

我们希望对SVM的基础行求解得到模型：

$$f(x) = \mathbf{w}^T \mathbf{x} + b$$

■ 拉格朗日乘子法：

■ 凸二次规划：

即优化(最小化或最大化)多个变量的二次函数，并服从于这些变量的线性约束。

■ 意义：

■ 在极值点，两函数的梯度在交点相切。

- 梯度与等高线的切线是垂直的。
- 对偶问题：
通过拉格朗日乘子法可将SVM基本型转为对偶问题
目标函数：

$$L(w, b, \alpha) = \frac{1}{2} \|w\|^2 + \sum_{i=1}^m \alpha_i (1 - y_i (w^T x_i + b))$$

其中：

前面是正则项；

对基本型的每条约束加上拉格朗日乘子 $\alpha_i \geq 0$

目标函数求w和b的偏导：

$$\begin{aligned} w &= \sum_{i=1}^m \alpha_i y_i x_i \\ 0 &= \sum_{i=1}^m \alpha_i y_i \end{aligned}$$

对偶问题：

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j x_i^T x_j \\ \text{s.t.} \quad & \sum_{i=1}^m \alpha_i y_i = 0 \\ & \alpha_i \geq 0, \quad i = 1, 2, \dots, m \end{aligned}$$

- 最终模型：
求解 α ，求出w和b可得：

$$\begin{aligned} f(x) &= w^T x + b \\ &= \sum_{i=1}^m \alpha_i y_i x_i^T x + b \end{aligned}$$

求解过程必须满足KKT：

$$\begin{cases} \alpha_i \geq 0 \\ y_i f(x_i) - 1 \geq 0 \\ \alpha_i (y_i f(x_i) - 1) = 0 \end{cases}$$

其中：

如果 $\alpha_i = 0$ ，表示该样本不会在最终模型求和中出现，也就是这个样本不会影响到模型；

如果 $\alpha_i > 0$ ，表示该样本是支持向量，影响模型的形成；

意义在于，训练完后，大多数训练样本不需要保留，最终模型仅与支持向量有关

◦ 如何求解 α ：

由于是二次规划问题，不能用梯度下降，常采用SMO。

▪ 什么是SMO：

在KKT约束情况下，SMO每次选择两个变量 $\alpha_i \alpha_j$ ，并固定其他参数，求解获得更新后的 $\alpha_i \alpha_j$ ，重复这个过程。总的来说 $\alpha_i \alpha_j$ 差距越大越好。

• 核函数：

◦ 什么是核函数：

对于线性不可分的问题，可以讲样本从原始空间映射到一个更高纬度的空间，使得样本在这个高维空间内线性可分。

◦ 为什么要用核函数：

训练样本是线性不可分的情况下（例如异或）可以采用核函数。

◦ 除了核函数还有什么能处理噪点：

核函数适合处理噪点过多的现象，软间隔适合处理噪点较少的现象。

◦ 核函数会增加计算量吗：

不会，核函数是在原始空间内计算内积，不必在高维空间计算内积。

◦ 核函数的对偶问题：

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \kappa(x_i, x_j) \\ \text{s.t.} \quad & \sum_{i=1}^m \alpha_i y_i = 0 \\ & \alpha_i \geq 0, \quad i = 1, 2, \dots, m \end{aligned}$$

◦ 核函数选择：

核函数的选择是支持向量机最大的变数，选择不好往往映射到一个不合适的空间，导致性能降低。

◦ 常见的核函数：

线性核

多项式核

高斯核

拉普拉斯核

Sigmoid核

• 软间隔：

- 有了核函数为什么还要使用软间隔：
 - 线性可分，即能找到超平面，对于硬间隔支持向量机
 - 部分点不可分，总体近似可分，近似线性可分，对应软间隔支持向量机
 - 线性不可分，需要用到核函数

- 什么是软间隔：

软间隔引入松弛变量，允许某些样本不满足硬间隔的约束条件。

- 损失函数：

hinge损失：

$$\min_{w,b} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^m \max(0, 1 - y_i (w^T x_i + b))$$

$$\begin{aligned} \text{s.t.} \quad & y_i (w^T x_i + b) \geq 1 - \xi_i \\ & \xi_i \geq 0, i = 1, 2, \dots, m \end{aligned}$$

其中：

ξ_i 为松弛变量，大于等于0，每个样本都对应一个松弛变量。

C是一个常数，当C无限大，函数必须满足约束；当C是有限值时，允许一些样本不满足约束。

求解：

拉格朗日，但是与硬间隔的区别是KKT约束不同。

- 软间隔的模型与什么有关：

仅与支持向量有关。

- 损失函数的正则化：

L2范数倾向于w的分量取值尽可能的均匀，非零分量的个数尽量稠密；

L1范数倾向于w分量尽可能的稀疏，分零分量尽可能的少。

- 多分类：

https://blog.csdn.net/csdn_lzw/article/details/80170178

- SVM的回归问题：